

# 矩阵分析及其应用

孔贺

南科大，自动化与智能制造学院

kongh@sustech.edu.cn

# 课程结构

- 一. 线性代数基本知识回顾 (3 个学时)
- 二. 线性空间与线性映射 (12 个学时)
- 三.  $\lambda$ -矩阵与 Jordan 标准型 (8 个学时)
- 四. 内积空间与矩阵分解 (12 个学时)
- 五. 范数及其他 (8 个学时)

- ① 第一章：线性代数知识回顾
- ② 第二章：线性空间与线性映射
- ③ 第三章： $\lambda$ -矩阵与 Jordan 标准型
- ④ 第四章：内积空间
  - 4.1 内积与 Gram 矩阵
  - 4.2 标准正交基与酉矩阵
  - 4.3 正交投影与最佳逼近
  - 4.4 受限最小二乘
  - 4.5 矩阵的广义逆
  - 4.6 正规矩阵
  - 4.7 Hermite 矩阵与 Hermite 二次型
  - 4.8 矩阵的奇异值分解

## 4.1 内积与 Gram 矩阵

定义：假设  $V$  是实数域  $\mathbf{R}$  上的线性空间。若存在映射

$$\tau : V \times V \rightarrow \mathbf{R}$$

且其满足以下条件：

- 1. 对称性，即对任意  $\alpha, \beta \in V$ ，有

$$\langle \alpha, \beta \rangle = \langle \beta, \alpha \rangle$$

- 2. 对第二个变元线性，即对任意  $\alpha, \beta, v \in V$ ， $g, h \in \mathbf{R}$ ，有

$$\langle \alpha, \beta g + v h \rangle = \langle \alpha, \beta \rangle g + \langle \alpha, v \rangle h$$

- 3. 正定性，即对任意的  $\alpha \in V$ ，有

$$\langle \alpha, \alpha \rangle \geq 0;$$

当且仅当  $\alpha = 0$  的时候有  $\langle \alpha, \alpha \rangle = 0$

则我们称其为  $V$  上的一个内积，并记为  $\tau(\alpha, \beta) = \langle \alpha, \beta \rangle$ 。特别的，称定义有如上内积的（有限维）线性空间为（欧几里得）内积空间。

# 内积性质的几点说明

- 对任意  $\alpha \in V$ , 有  $\langle 0, \alpha \rangle = 0$ 。
- 双线性: 注意以下事实, 若我们固定  $\alpha$ , 让  $\beta$  变化, 则由内积可决定以下的映射

$$\langle \alpha, \cdot \rangle : V \rightarrow \mathbf{R}$$

也可记为

$$\beta \mapsto \langle \alpha, \beta \rangle$$

那么内积定义中的第 2 个性质是在说上述映射是从  $V$  到  $\mathbf{R}$  的线性映射, 因此称其对第二个变元线性。综合第 1, 2 个性质, 我们可以得出内积对第一个变元也是线性的。

- 根据双线性的性质, 计算

$$\langle u_1 3 + u_2 2, v_1 4 + v_2 5 \rangle$$

# 欧式空间举例

- 实数域  $\mathbb{R}$  上的标准欧式空间  $\mathbb{R}^n$  ( $\mathbb{R}^n$  上的标准内积)

$$\begin{aligned}\langle x, y \rangle &= x^T y \\ &= \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}\end{aligned}$$

- 非标准内积

$$\langle x, y \rangle = x_1 y_1 + \frac{1}{2} x_1 y_2 + \frac{1}{2} x_2 y_1 + x_2 y_2$$

- 几何空间作为欧式空间
- 函数空间的内积

定义：假设  $V$  是复数域  $C$  上的线性空间。若存在映射

$$\tau : V \times V \rightarrow C$$

且其满足以下条件：

- 1. 共轭对称性，即对任意  $\alpha, \beta \in V$ ，有

$$\langle \alpha, \beta \rangle = \overline{\langle \beta, \alpha \rangle}$$

- 2. 对第二个变元线性，即对任意  $\alpha, \beta, \nu \in V$ ， $g, h \in C$ ，有

$$\langle \alpha, \beta g + \nu h \rangle = \langle \alpha, \beta \rangle g + \langle \alpha, \nu \rangle h$$

- 3. 对任意的  $\alpha \in V$ ，有

$$\langle \alpha, \alpha \rangle \geq 0;$$

当且仅当  $\alpha = 0$  的时候有  $\langle \alpha, \alpha \rangle = 0$

则我们称其为  $V$  上的一个复内积。特别的，称定义有如上复内积的有限维线性空间为复欧几里得空间，简称酉空间。欧式空间与酉空间通称为内积空间（以下大多数情况下，我们会讨论酉空间）。

# 复内积性质与举例

- 对任意  $\alpha \in \mathbf{V}$ , 有  $\langle 0, \alpha \rangle = 0$ 。
- 复内积对第一个变元是共轭线性的。
- 复数域  $\mathbf{C}$  上的标准酉空间  $\mathbf{C}^n$  ( $\mathbf{C}^n$  上的标准内积)

$$\begin{aligned}\langle x, y \rangle &= \bar{x}^T y \\ &= \begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \cdots & \bar{x}_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}\end{aligned}$$



# 线性组合的内积的矩阵表示

$$\left\langle \sum_{i=1}^s \alpha_i g_i, \sum_{j=1}^t \beta_j h_j \right\rangle$$
$$= \begin{bmatrix} \overline{g_1} & \overline{g_2} & \cdots & \overline{g_s} \end{bmatrix} [\langle \alpha_i, \beta_j \rangle]_{s \times t} \begin{bmatrix} h_1 \\ h_2 \\ \vdots \\ h_t \end{bmatrix}$$

因此，只要知道两个向量组之间，每对向量的内积，那么由这两个向量组各自任意做线性组合得到的一对向量的内积，可以由上述各对向量的内积（向量组的 Gram 矩阵）和线性组合的系数得出。

# 向量组的 Gram 矩阵

- 假设  $\alpha_1, \alpha_2, \dots, \alpha_s$  是  $n$  维复内积空间的一个向量组，我们称矩阵

$$\mathcal{G}(\alpha_1, \alpha_2, \dots, \alpha_s) := [\langle \alpha_i, \alpha_j \rangle]_{s \times s} \in \mathbf{C}^{s \times s}$$

为上述向量组的 Gram 矩阵，记为  $\mathcal{G}(\{\alpha_i\})$ 。

- 假设  $\alpha_1, \alpha_2, \dots, \alpha_s; \beta_1, \beta_2, \dots, \beta_t$  是  $n$  维复内积空间的两个向量组，我们称矩阵

$$\mathcal{G}(\alpha_1, \alpha_2, \dots, \alpha_s; \beta_1, \beta_2, \dots, \beta_t) := [\langle \alpha_i, \beta_j \rangle]_{s \times t} \in \mathbf{C}^{s \times t}$$

为上述两个向量组的交互 Gram 矩阵，记为  $\mathcal{G}(\{\alpha_i\}, \{\beta_j\})$ 。

- 注：矩阵乘积作为两向量组的交互 Gram 矩阵。

# 向量的长度和夹角

- 定义：假设  $V$  为酉空间，给定向量  $\alpha, \beta \in V$ ，称  $\|\alpha\| := \sqrt{\langle \alpha, \alpha \rangle}$  为向量的长度（模）；称  $d(\alpha, \beta) := \|\alpha - \beta\|$  为向量  $\alpha$  与  $\beta$  之间的距离。
- 定理：假设  $V$  为酉空间，给定向量  $\alpha \in V$ ，则其长度  $\|\alpha\|$  具有以下性质
  - (1) 非负性： $\|\alpha\| \geq 0$ ，当且仅当  $\alpha = 0$  时  $\|\alpha\| = 0$
  - (2) 齐次性： $\|\alpha k\| = |k| \|\alpha\|$ ，其中  $k$  为任意数
  - (3) 满足三角不等式： $\|\alpha + \beta\| \leq \|\alpha\| + \|\beta\|$
  - (4) 满足 Cauchy-Schwartz 不等式： $|\langle \alpha, \beta \rangle| \leq \|\alpha\| \|\beta\|$
  - (5) 满足平行四边形公式： $\|\alpha + \beta\|^2 + \|\alpha - \beta\|^2 = 2(\|\alpha\|^2 + \|\beta\|^2)$

- 基于 Cauchy-Schwartz 不等式, 对实内积空间中的向量有

$$-1 \leq \frac{\langle \alpha, \beta \rangle}{\|\alpha\| \|\beta\|} \leq 1$$

- 定义: 假设  $\alpha, \beta$  为欧式空间中的两个非零向量, 我们称

$$\varphi := \arccos \frac{\langle \alpha, \beta \rangle}{\|\alpha\| \|\beta\|}$$

为两个向量的夹角。

- 定义: 假设  $\alpha, \beta$  为酉空间中的两个非零向量, 若  $\langle \alpha, \beta \rangle = 0$ , 则称  $\alpha, \beta$  相互正交, 记为  $\alpha \perp \beta$ 。
  - 在欧式空间中, 两个向量正交意味着其夹角为  $\frac{\pi}{2}$ 。

## 4.2 标准正交基与酉矩阵

**定义：**假设  $V$  为  $C$  上的内积空间，给定  $V$  中的非零向量  $\alpha_1, \alpha_2, \dots, \alpha_s$ ，考虑其组成的向量组。

- 若此向量组中的任意两个向量都正交，即  $\alpha_i \perp \alpha_j$ ，其中  $i, j = 1, 2, \dots, s$  且  $i \neq j$ ，则称其为正交向量组，简称**正交组**。
- 若正交向量组又满足标准性，即  $\|\alpha_i\| = 1, i = 1, 2, \dots, s$ ，则称其为标准正交向量组，简称**标准正交组**。
- 若标准正交向量组同时还是  $V$  的一组基，则称其为**标准正交基**。

**定理：**给定内积空间中的一个向量组。

- 若其为正交向量组，则其线性无关（逆否命题？）。
- 其为正交组的充要条件是其 Gram 矩阵为非奇异对角矩阵。
- 其为标准正交组的充要条件是其 Gram 矩阵为单位阵。

## 内积空间中标准正交组的好处

**定理：** 给定复内积空间  $V$  中的一个正交组  $\alpha_1, \alpha_2, \dots, \alpha_s$ ，以及  $\alpha \in V$ 。若有

$$\begin{aligned}\alpha &= \alpha_1 k_1 + \alpha_2 k_2 + \dots + \alpha_s k_s \\ &= \begin{bmatrix} \alpha_1 & \alpha_2 & \dots & \alpha_s \end{bmatrix} \begin{bmatrix} k_1 \\ k_2 \\ \vdots \\ k_s \end{bmatrix}\end{aligned}$$

则

$$k_i = \frac{\langle \alpha_i, \alpha \rangle}{\langle \alpha_i, \alpha_i \rangle}, \quad i = 1, 2, \dots, s$$

特别的，若  $\alpha_1, \alpha_2, \dots, \alpha_s$  为标准正交组，则有

$$k_i = \langle \alpha_i, \alpha \rangle, \quad i = 1, 2, \dots, s$$

**举例及问题：** 对内积空间，标准正交基的存在性？

## Gram-Schmidt 正交化方法

给定  $n$  维内积空间  $V$  中的  $s$  个线性无关的向量  $\alpha_1, \alpha_2, \dots, \alpha_s$ , 那么可以通过 Gram-Schmidt 正交化方法将其改造成标准向量组:

- (1) 正交化:

$$\beta_1 = \alpha_1$$

$$\beta_2 = \alpha_2 - \beta_1 \square$$

$$\beta_3 = \alpha_3 - (\beta_1 \square + \beta_2 \square)$$

$$\vdots$$

$$\beta_s = \alpha_s - (\beta_1 \square + \beta_2 \square + \dots + \beta_{s-1} \square)$$

- (2) 单位化:

$$\tilde{\beta}_1 = \frac{\beta_1}{\|\beta_1\|}, \tilde{\beta}_2 = \frac{\beta_2}{\|\beta_2\|}, \dots, \tilde{\beta}_s = \frac{\beta_s}{\|\beta_s\|}$$

**注:** 举例。对任意  $n$  维内积空间, Gram-Schmidt 正交化方法保证了标准正交基的存在性, 从而使得任一内积空间同构于相同维数的标准内积空间。

# Gram-Schmidt 正交化的矩阵表达—矩阵的 QR 分解

定理：给定  $A \in \mathbb{C}^{n \times s}$  且  $A$  列满秩，则存在唯一的矩阵对  $Q \in \mathbb{C}^{n \times s}$  和  $R \in \mathbb{C}^{s \times s}$  满足如下条件

- (1)  $A = QR$
- (2)  $Q^H Q = I_s$ ，即  $Q$  的列向量是标准酉空间  $\mathbb{C}^n$  中的标准正交组中的  $s$  个向量
- (3)  $R$  是对角线为正实数的上三角矩阵

注明：

- (1) 需要证明什么，如何证？
- (2) 特别的，如果  $A \in \mathbb{C}^{n \times n}$  且  $A$  满秩，则  $\overline{Q}^T Q = I_n$ ，即  $Q$  为通常所说的酉矩阵



# 酉矩阵

定义：给定  $U \in \mathbb{C}^{n \times n}$ ，若其满足

$$U^H U = I_n$$

则称  $U$  为酉矩阵。相应的，实矩阵被称为正交矩阵，若

$$U^T U = I_n$$

注：酉矩阵的两种解读

- (1) 由标准酉空间中的任一标准正交基所拼成（回忆标准内积）。
- (2)  $U$  为酉矩阵，若  $U^{-1} = U^H$ 。

定义：给定  $A, B \in \mathbb{C}^{n \times n}$ ，若有酉矩阵  $U \in \mathbb{C}^{n \times n}$  使得

$$U^H A U = B$$

则称  $A$  与  $B$  酉相似。

# 酉矩阵保持度量

定理：给定  $U \in \mathbb{C}^{n \times n}$ ，则下列说法等价

- (1)  $U$  为酉矩阵，即其列向量组是标准酉空间  $\mathbb{C}^n$  中的一个标准正交基
- (2)  $U^H$  为酉矩阵，即其行向量组的共轭转置是标准酉空间  $\mathbb{C}^n$  中的一个标准正交基
- (3)  $U^H U = I_n$
- (4)  $U U^H = I_n$
- (5) 对任意  $x \in \mathbb{C}^n$ ，有  $\|Ux\| = \|x\|$
- (6) 对任意  $x, y \in \mathbb{C}^n$ ，有  $\langle Ux, Uy \rangle = \langle x, y \rangle$

# 酉矩阵的例子

例 1: 回忆 2D 平面中旋转矩阵的表示 (第一章)




图: Fig. 2.7, Peter Corke, Robotics, Vision and Control (Second Edition)

例 2: 3D 空间中绕  $x$  轴的旋转矩阵

## 4.3 正交投影与最佳逼近

问题：假设  $V$  是  $C$  上的内积空间，给定  $\beta \in V$ ， $W$  是  $V$  的一个有限维子空间

- 求  $\alpha^* \in W$  使得

$$d(\alpha^*, \beta) = \min \{d(\alpha, \beta) : \alpha \in W\}$$

其中， $d(\alpha, \beta) := \|\alpha - \beta\|$  表示向量  $\alpha$ ， $\beta$  之间的距离。

- 换言之，我们要找到  $\alpha^*$  使得

$$d(\alpha^*, \beta) \leq d(\alpha, \beta), \text{ 对任意 } \alpha \in W$$

- 用优化问题的形式可表示为

$$\alpha^* = \arg \min_{\alpha \in W} \|\alpha - \beta\|$$

对这样一个问题，我们关心的是什么？

## W 为一维子空间的情形（用欧式空间为例来说明）

对此情形，有  $W = \text{span}\{\alpha\}$ ,  $\alpha \neq 0$ ，且  $W$  中的所有元素可表示为

$$W = \text{span}\{\alpha k\}, \text{ 其中 } k \in \mathbf{R}$$

- 解法一：化为函数极值问题

$$\begin{aligned} f(k) &= \|\alpha k - \beta\|^2 = \langle \alpha k - \beta, \alpha k - \beta \rangle \\ &= \langle \alpha, \alpha \rangle k^2 - 2 \langle \alpha, \beta \rangle k + \langle \beta, \beta \rangle \end{aligned}$$

- 解法二：勾股定理

假设  $\beta - \alpha k^* \perp W$ ，则有

$$\beta - \alpha k = \beta - \alpha k^* + \alpha(k^* - k)$$

其中  $\alpha(k^* - k) \in W$ ，且  $\beta - \alpha k^* \perp \alpha(k^* - k)$ 。由勾股定理可知

$$\begin{aligned} \|\beta - \alpha k\|^2 &= \|\beta - \alpha k^*\|^2 + \|\alpha(k^* - k)\|^2 \\ &\geq \|\beta - \alpha k^*\|^2 \end{aligned}$$

即， $\beta - \alpha k^* \perp W$  中的  $k^*$  为所求。

- 例子

## W 为多维子空间的情形

定理：假设  $V$  是  $C$  上的内积空间，给定  $\beta \in V$ ， $W$  是  $V$  的一个  $s$  维子空间，那么

- (1) 存在唯一的  $\alpha^* \in W$  使得

$$d(\alpha^*, \beta) = \min \{d(\alpha, \beta) : \alpha \in W\}$$

- (2) 假设  $w_1, w_2, \dots, w_s$  为  $W$  的一组基，记

$$W = \begin{bmatrix} w_1 & w_2 & \cdots & w_s \end{bmatrix}, \alpha^* = Wk^* = W \begin{bmatrix} k_1^* \\ k_2^* \\ \vdots \\ k_s^* \end{bmatrix}$$

则

$$k^* = \mathcal{G}^{-1}(\{w_i\}) \mathcal{G}(\{w_i\}, \beta), \alpha^* = Wk^*$$

- 若  $w_1, w_2, \dots, w_s$  均为数域上的向量，则有

$$k^* = (W^H W)^{-1} W^H \beta, \alpha^* = Wk^* = W (W^H W)^{-1} W^H \beta$$

- 例子：给定复数域上的矩阵  $A \in \mathbb{C}^{n \times s}$ ，假设其列满秩，那么子空间  $\text{im}(A)$  对应的正交投影矩阵为

$$P_A = A(A^H A)^{-1} A^H$$

即，给定向量  $\beta \in \mathbb{C}^n$ ，其在子空间  $\text{im}(A)$  所对应的投影为

$$\alpha^* = P_A \beta = A(A^H A)^{-1} A^H \beta$$

对于给定的  $A$ ，线性映射  $\beta \mapsto \alpha^*$  是从酉空间  $\mathbb{C}^n$  到子空间  $W = \text{im}(A)$  的投影算子，由  $P_A$  决定。

- 投影矩阵的性质
  - (1) Hermite 性
  - (2) 幂等的
  - (3) 与子空间秩的一致性

## 最小二乘数据拟合

对“因变量”  $y$  和“自变量”  $x_1, x_2, \dots, x_p$  做  $n$  次观测，得到如下数据

编号	$y$	$x_0$	$x_1$	$x_2$	$\dots$	$x_p$
1	$y_1$	1	$x_{11}$	$x_{12}$	$\dots$	$x_{1p}$
2	$y_2$	1	$x_{21}$	$x_{22}$	$\dots$	$x_{2p}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$
$n$	$y_n$	1	$x_{n1}$	$x_{n2}$	$\dots$	$x_{np}$

实际中，为了方便，经常补充常值变量  $x_0 \equiv 1$ 。我们要寻找“经验公式”

$$y = x_0 m_0 + x_1 m_1 + x_2 m_2 + \dots + x_p m_p = \begin{bmatrix} 1 & x_1 & x_2 & \dots & x_p \end{bmatrix} \begin{bmatrix} m_0 \\ m_1 \\ m_2 \\ \vdots \\ m_p \end{bmatrix}$$

即求参数  $m_0, m_1, m_2, \dots, m_p$  实现“最优拟合”。



# 最小二乘准则的几何解释

最小二乘的几何本质是“因变量”  $y$  的观测值组成的向量向“自变量”  $x_0, x_1, x_2, \dots, x_p$  的  $n$  次观测值所组成的矩阵的像空间做正交映射：

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_p \end{bmatrix} \in V = \mathbf{R}^n, \quad m = \begin{bmatrix} m_0 \\ m_1 \\ \vdots \\ m_p \end{bmatrix}$$
$$a_0 = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}, \quad a_1 = \begin{bmatrix} x_{11} \\ x_{21} \\ \vdots \\ x_{n1} \end{bmatrix}, \quad a_2 = \begin{bmatrix} x_{12} \\ x_{22} \\ \vdots \\ x_{n2} \end{bmatrix}, \dots, \quad a_p = \begin{bmatrix} x_{1p} \\ x_{2p} \\ \vdots \\ x_{np} \end{bmatrix},$$
$$X = \begin{bmatrix} a_0 & a_1 & a_2 & \cdots & a_p \end{bmatrix} \in \mathbf{R}^{n \times (p+1)}, \quad W = \text{im}(X)$$

假设  $X$  列满秩，因此有

$$m^* = (X^T X)^{-1} X^T Y$$

# 最小二乘最优解的计算

继续考虑上面的最优拟合的例子，最优解

$$m^* = (X^T X)^{-1} X^T Y \quad (1)$$

- 实际中，矩阵求逆主要面临以下弊端：
  - (1) 复杂度较高
  - (2) 易引进计算误差
- 工程应用需要有复杂度更低、更数据稳定的方法
- 注意：这里我们假设  $X$  为列满秩，那么其必有唯一的  $QR$  分解：

$$X = QR$$

其中  $Q$  为标准正交阵， $R$  是对角线正实数的上三角矩阵。带入式 (1) 得

$$m^* = R^{-1} Q^T Y$$

- 通过  $QR$  分解求解最小二乘问题的方法
  - (1)  $QR$  分解
  - (2) 计算  $Q^T Y$
  - (3) 代入法求解  $Rm^* = Q^T Y$

## 应用举例 1: $k$ -均值聚类

- 假设有  $N$  个  $n$  维向量,  $x_1, \dots, x_n$ , 聚类的目标是
  - 将这些向量分为  $k$  组或者  $k$  类
  - 且每组或者每类中的向量都离彼此比较接近




图: Fig. 4.1, Boyd and Vandenberghe, 2018

- 举例: 家用能源消耗数据分析与处理  $R^{24}$

# 聚类的核心要素

- 确认分组 (cluster assignments):  $c_1, \dots, c_N$
- 组代表 (group representative), 其不一定是现有的数据点
- 聚类的目标函数/代价函数

$$J^{clust} = \frac{\|x_1 - z_{c_1}\|^2 + \dots + \|x_N - z_{c_N}\|^2}{N}$$

# 如何确认分组和组代表，以及二者的先后顺序？

- 当组代表固定下来的时候

$$J^{clust} = \frac{\min_{j=1,\dots,k} \|x_1 - z_j\|^2 + \dots + \min_{j=1,\dots,k} \|x_N - z_j\|^2}{N}$$

- 分组固定的时候，合理选择组代表

$$J^{clust} = J_1 + \dots + J_k$$

$$J_j = \frac{1}{N} \sum_{i \in G_j} \|x_i - z_j\|^2$$

$$z_j = \frac{1}{|G_j|} \sum_{i \in G_j} x_i$$

# $k$ -均值聚类

---

**Algorithm 4.1**  $k$ -MEANS ALGORITHM

---

**given** a list of  $N$  vectors  $x_1, \dots, x_N$ , and an initial list of  $k$  group representative vectors  $z_1, \dots, z_k$

repeat until convergence

1. *Partition the vectors into  $k$  groups.* For each vector  $i = 1, \dots, N$ , assign  $x_i$  to the group associated with the nearest representative.
  2. *Update representatives.* For each group  $j = 1, \dots, k$ , set  $z_j$  to be the mean of the vectors in group  $j$ .
- 

图: Algorithm. 4.1, Boyd and Vandenberghe, 2018

# $k$ -均值聚类




图: Fig. 4.2, Boyd and Vandenberghe, 2018

## 应用举例 2: 卡尔曼滤波 (Kalman filtering)

考虑如下系统

$$\begin{cases} x_{k+1} = Ax_k + Bu_k + w_k \\ y_k = Cx_k + Du_k + v_k \end{cases}$$

其中

- $x_k \in \mathbf{R}^n$ ,  $u_k \in \mathbf{R}^m$ ,  $y_k \in \mathbf{R}^p$  分别代表系统的状态、已知控制输入、系统输出。
- $w_k \in \mathbf{R}^n$ ,  $v_k \in \mathbf{R}^p$  分别代表系统的过程噪声、量测噪声。
- 假设

$$\mathcal{E} \begin{bmatrix} w_k \\ v_k \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\mathcal{E} \left[ \begin{bmatrix} w_k \\ v_l \end{bmatrix} \begin{bmatrix} w_i^T & v_j^T \end{bmatrix} \right] = \begin{bmatrix} Q\delta_{ki} & S\delta_{kj} \\ S^T\delta_{li} & R\delta_{lj} \end{bmatrix}$$



# 滤波、预测与平滑

- 所谓的“滤波与预测 (filtering and prediction)”

$$\hat{x}_{k|k-1} := \mathcal{E} [x_k \mid y_0, y_1, y_2, \dots, y_{k-1}]$$

$$\hat{x}_{k|k} := \mathcal{E} [x_k \mid y_0, y_1, y_2, \dots, y_k]$$

- 对应的估计误差的协方差

$$\Sigma_{k|k-1} := \mathcal{E} [(x_k - \hat{x}_{k|k-1})(x_k - \hat{x}_{k|k-1})^T]$$

$$\Sigma_{k|k} := \mathcal{E} [(x_k - \hat{x}_{k|k})(x_k - \hat{x}_{k|k})^T]$$

- 另有所谓的“平滑” (smoothing)

- (1) Fix-point smoothing

$$\hat{x}_{0|k} := \mathcal{E} [x_0 \mid y_0, y_1, y_2, \dots, y_k]$$

- (2) Fix-lag smoothing

$$\hat{x}_{k-T|k} := \mathcal{E} [x_{k-T} \mid y_0, y_1, y_2, \dots, y_k]$$

- (3) Fix-length smoothing

$$[\hat{x}_{k-T|k}, \hat{x}_{k-T+1|k}, \dots, \hat{x}_{k|k}] := \mathcal{E} [x_{k-T}, x_{k-T+1}, \dots, x_k \mid y_0, y_1, y_2, \dots, y_k]$$

# 卡尔曼滤波器的迭代过程

- 1. Initialization
- 2. Filtering
  - Measurement update

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + L_k(y_k - C\hat{x}_{k|k-1} - Du_k) \quad (2)$$

- Filter gain and filtered error covariance

$$\begin{aligned} L_k &= \Sigma_{k|k-1} C^T (C \Sigma_{k|k-1} C^T + R)^{-1} \\ \Sigma_{k|k} &= \Sigma_{k|k-1} - L_k C \Sigma_{k|k-1} \end{aligned}$$

- 3. Prediction:
  - Time update

$$\hat{x}_{k+1|k} = A\hat{x}_{k|k} + Bu_k = A\hat{x}_{k|k-1} + K_k(y_k - \hat{y}_{k|k-1}) \quad (3)$$

- Prediction gain and prediction error covariance

$$\begin{aligned} K_k &= (A \Sigma_{k|k-1} C^T + S)(C \Sigma_{k|k-1} C^T + R)^{-1} \\ \Sigma_{k+1|k} &= A \Sigma_{k|k-1} A^T - K_k (A \Sigma_{k|k-1} C^T + S)^T + Q \end{aligned}$$

- 4. New measurement arrives and go to step 2

# 卡尔曼滤波器的最优性—三种不同的解读

- (a) 基于正交投影
  - R. E. Kalman, A new approach to linear filtering and prediction problems, 1960 (one of the 25 seminal papers in control, 1932-1981)
- (b) 基于概率论：最大化后验概率状态估计
- (c) 基于最小二乘
  - (1) 噪声为高斯的情况下，卡尔曼滤波器是无偏的、估计误差协方差最小的线性滤波器
  - (2) 噪声为非高斯且均值为零的时候，卡尔曼滤波器依然是无偏的、估计误差协方差最小的线性滤波器

# 理论、直觉和应用的“三位一体”

## INTRODUCTION

### The Nature of Probability Theory

#### 1. THE BACKGROUND

Probability is a mathematical discipline with aims akin to those, for example, of geometry or analytical mechanics. In each field we must carefully distinguish three aspects of the theory: (a) the formal logical content, (b) the intuitive background, (c) the applications. The character, and the charm, of the whole structure cannot be appreciated without considering all three aspects in their proper relation.

图: William Feller, An Introduction to Probability Theory and Its Applications, 1950

# 威廉·费勒



**图:** William Feller, 1906-1970, 克罗地亚裔美国数学家, 20 世纪最伟大的概率学家之一。师从著名数学家希尔伯特和柯朗, 年仅 20 岁就获得哥廷根大学的博士学位, 对近代概率论的发展做出了卓越贡献。特别是他的两本专著 (《概率论及其应用》, 共 2 卷), 影响了世界各国几代概率论及相关领域的人士。

## 4.4 受限最小二乘

- 线性受限最小二乘问题为：

$$\begin{aligned} & \text{minimize} && \|Ax - b\|^2 \\ & \text{subject to} && Cx = d \end{aligned}$$

- 待求解变量为  $n$  维向量  $x$
- 已知：  $A$  为  $m \times n$  矩阵，  $b$  为  $m$  维向量，  $C$  为  $p \times n$  矩阵，  $d$  为  $p$  维向量
- 目标函数为  $\|Ax - b\|^2$
- 等式约束为  $Cx = d$
- 如果  $x$  满足  $Cx = d$ ，则  $x$  是可行解
- 若  $\hat{x}$  满足  $C\hat{x} = d$ ，并且对于任意满足  $Cx = d$  的  $n$  维向量  $x$ ，有  $\|A\hat{x} - b\|^2 \leq \|Ax - b\|^2$ ，则  $\hat{x}$  为问题的解。

# 通过微积分求最优条件

求解约束优化问题：

$$\begin{array}{ll}\text{minimize} & f(x) = \|Ax - b\|^2 \\ \text{subject to} & c_i^T x = d_i, \quad i = 1, \dots, p\end{array}$$

① 引入拉格朗日乘子  $z_1, \dots, z_p$ ，得到拉格朗日函数：

$$L(x, z) = f(x) + z_1(c_1^T x - d_1) + \dots + z_p(c_p^T x - d_p)$$

② 对  $x$  和  $z$  分别求偏导数，并令其等于零：

$$\frac{\partial L}{\partial x_i}(\hat{x}, z) = 0, \quad i = 1, \dots, n; \quad \frac{\partial L}{\partial z_i}(\hat{x}, z) = 0, \quad i = 1, \dots, p$$

# 通过微积分求最优条件

- 对于损失函数  $L$ , 我们已知  $\frac{\partial L}{\partial z_i}(\hat{x}, z) = c_i^T \hat{x} - d_i = 0$
- 前  $n$  个方程更为重要:

$$\frac{\partial L}{\partial x_i}(\hat{x}, z) = 2 \sum_{j=1}^n (A^T A)_{ij} \hat{x}_j - 2 (A^T b)_i + \sum_{j=1}^p z_j c_j = 0$$

- 以矩阵-向量形式表示:  $2 (A^T A) \hat{x} - 2 A^T b + C^T z = 0$
- 将其与  $C \hat{x} = d$  相结合, 得到 KKT 条件:

$$\begin{bmatrix} 2A^T A & C^T \\ C & 0 \end{bmatrix} \begin{bmatrix} \hat{x} \\ z \end{bmatrix} = \begin{bmatrix} 2A^T b \\ d \end{bmatrix}$$

这是一个包含  $n + p$  个变量  $\hat{x}, z$  的方程组

- KKT 方程是无约束最小二乘问题正规方程的扩展



# 约束最小二乘问题的解法

- 假设 KKT 矩阵是可逆的，我们有：

$$\begin{bmatrix} \hat{x} \\ z \end{bmatrix} = \begin{bmatrix} 2A^T A & C^T \\ C & 0 \end{bmatrix}^{-1} \begin{bmatrix} 2A^T b \\ d \end{bmatrix}$$

- 当且仅当  $C$  的行线性无关且  $\begin{bmatrix} A \\ C \end{bmatrix}$  的列线性无关时，KKT 矩阵是可逆的
- 这意味着  $m + p \geq n$ ，且  $p \leq n$

# 通过 QR 分解求解约束最小二乘问题

**Algorithm** Constrained least squares via QR factorization

**given** an  $m \times n$  matrix  $A$  and a  $p \times n$  matrix  $C$  that satisfying the invertibility condition of the KKT matrix, an  $m$ -vector  $b$ , and a  $p$ -vector  $d$ .

1. QR factorizations. Compute the QR factorizations

$$\begin{bmatrix} A \\ C \end{bmatrix} = \begin{bmatrix} Q_1 \\ Q_2 \end{bmatrix} R, \quad Q_2^T = \tilde{Q} \tilde{R}$$

2. Compute  $\tilde{R}^{-T}d$  by forward substitution.
3. Form right-hand side and solve

$$\tilde{R}w = 2\tilde{Q}^T Q_1^T b - 2\tilde{R}^{-T}d$$

via back substitution.

4. Compute  $\hat{x}$ . Form right-hand side and solve

$$R\hat{x} = Q_1^T b - (1/2)Q_2^T w$$

by back substitution.

# 非线性最小二乘

## 非线性方程组

- $n$  个未知数  $x_1, \dots, x_n$  的  $m$  个非线性方程组:

$$f_i(x_1, \dots, x_n) = 0, \quad i = 1, \dots, m$$

- $f_i(x) = 0$  是第  $i$  个方程;  $f_i(x)$  是第  $i$  个残差
- $x = (x_1, \dots, x_n)$  是  $n$  维向量
- 可以写成向量方程  $f(x) = 0$ , 其中  $f: \mathbf{R}^n \rightarrow \mathbf{R}^m$ ,

$$f(x) = (f_1(x), \dots, f_m(x))$$

- 当  $f$  是仿射时, 简化为  $m$  个线性方程组
- 若  $m > n$ , 方程组超定; 若  $m < n$ , 方程组欠定; 若  $m = n$ , 方程组“方阵” (square)

# 非线性最小二乘

- 寻找  $\hat{x}$  满足：

$$\text{minimize} \quad \|f(x)\|^2 = f_1(x)^2 + \cdots + f_m(x)^2$$

- 包含解方程  $f(x) = 0$  的问题作为特例
- 类似（线性）最小二乘，本身非常有用

# 最优性条件

- 最优性的必要条件:  $\nabla \|f(\hat{x})\|^2 = 0$
- 任何最优点都满足这个条件
- 有些点可能满足这个条件但不是最优点
- 可以表示为  $2Df(\hat{x})^T f(\hat{x}) = 0$
- $Df(\hat{x})$  是  $m \times n$  的导数或雅可比矩阵,

$$Df(\hat{x})_{ij} = \frac{\partial f_i}{\partial x_j}(\hat{x}), \quad i = 1, \dots, m, \quad j = 1, \dots, n$$

- 当  $f$  是仿射时, 最优性条件简化为正规方程

# 解决非线性最小二乘问题的困难性

- 解决非线性方程或非线性最小二乘问题（一般而言）要比解线性方程困难得多
- 甚至确定是否存在解都很困难
- 因此，实际中经常使用启发式算法（heuristics）：
  - 不能保证始终有效
  - 但在实践中通常表现良好（例如  $k$ -means）

# 基本思路

- 在任意点  $z$  处，我们可以形成仿射近似

$$\hat{f}(x; z) \approx f(z) + Df(z)(x - z)$$

- 只要  $x$  接近  $z$ ,  $\hat{f}(x; z) \approx f(x)$
- 我们可以通过线性最小二乘最小化  $\|\hat{f}(x; z)\|^2$
- 我们将迭代，其中  $z$  是当前迭代的点

# 基本高斯-牛顿算法

- 迭代  $x^{(1)}, x^{(2)}, \dots$
- 在第  $k$  次迭代时, 形成  $f$  在  $x^{(k)}$  处的仿射近似:

$$\hat{f}(x; x^{(k)}) = f(x^{(k)}) + Df(x^{(k)})(x - x^{(k)})$$

- 将  $x^{(k+1)}$  设置为  $\|\hat{f}(x; x^{(k)})\|^2$  的最小化器,

$$x^{(k+1)} = x^{(k)} - \left( Df(x^{(k)})^T Df(x^{(k)}) \right)^{-1} Df(x^{(k)})^T f(x^{(k)})$$



# 牛顿法 ( $m = n$ )

- 迭代  $x^{(1)}, x^{(2)}, \dots$
- 在第  $k$  次迭代时, 形成  $f$  在  $x^{(k)}$  处的仿射近似:

$$\hat{f}(x; x^{(k)}) = f(x^{(k)}) + Df(x^{(k)})(x - x^{(k)})$$

- 将  $x^{(k+1)}$  设置为  $\hat{f}(x; x^{(k)}) = 0$  的解

$$x^{(k+1)} = x^{(k)} - \left( Df(x^{(k)}) \right)^{-1} f(x^{(k)})$$

# Levenberg-Marquardt 算法

- 迭代  $x^{(1)}, x^{(2)}, \dots$
- 在第  $k$  次迭代时, 形成  $f$  在  $x^{(k)}$  处的仿射近似:

$$\hat{f}(x; x^{(k)}) = f(x^{(k)}) + Df(x^{(k)})(x - x^{(k)})$$

- 选择  $x^{(k+1)}$  为

$$\|\hat{f}(x; x^{(k)})\|^2 + \lambda^{(k)} \|x - x^{(k)}\|^2$$

的最小化器, 其中

$$\lambda^{(k)} > 0$$

- 我们希望  $\|\hat{f}(x; x^{(k)})\|^2$  很小, 但我们不希望  $x^{(k+1)}$  离  $x^{(k)}$  太远, 因为这时  $\hat{f}(x; x^{(k)}) \approx f(x)$  不再成立。

## 调整 $\lambda^{(k)}$

思路:

- 如果  $\lambda^{(k)}$  太大,  $x^{(k+1)}$  太接近  $x^{(k)}$ , 进展缓慢
- 如果太小,  $x^{(k+1)}$  可能离  $x^{(k)}$  很远, 仿射近似很差

更新机制:

- 如果  $\|f(x^{(k+1)})\|^2 < \|f(x^{(k)})\|^2$ , 接受新的  $x$  并减小  $\lambda$ :

$$\lambda^{(k+1)} = 0.8\lambda^{(k)}$$

- 否则, 增加  $\lambda$  并不更新  $x$ :

$$\lambda^{(k+1)} = 2\lambda^{(k)}, \quad x^{(k+1)} = x^{(k)}$$

## 4.5 矩阵的广义逆

### 矩阵的广义逆

- 问题：给定  $A \in \mathbf{C}^{n \times n}$ ，若  $A$  可逆，则线性方程组  $Ax = b$  存在唯一解  $x = A^{-1}b$ 。那么
  - 1. 若  $A$  不是方阵，即  $A \in \mathbf{C}^{m \times n}$ ，且线性方程组  $Ax = b$  的解若存在，可否用  $x = Hb$  的形式表示出来？
  - 2. 若  $A$  不是方阵且线性方程组  $Ax = b$  的解不存在，如何求其最好的近似解？
- 定义：考虑线性方程组

$$Ax = b$$

其中， $A \in \mathbf{C}^{m \times n}$ ， $b \in \mathbf{C}^m$ 。对于任意的  $b \in R(A)$ ，存在  $A^- \in \mathbf{C}^{n \times m}$  使得  $x = A^-b$  为线性方程组的解，则称  $A^-$  为矩阵  $A$  的广义逆。

# 广义逆的存在性与表示

## 矩阵的广义逆

- 定理：给定  $A \in \mathbf{C}^{m \times n}$ ，广义逆存在的充要条件是存在  $A^- \in \mathbf{C}^{n \times m}$  满足

$$AA^-A = A$$

即上述矩阵方程有解。

- 定理：给定  $A \in \mathbf{C}^{m \times n}$ ，假设其秩为  $r$ ， $P \in \mathbf{C}^{m \times m}$  和  $Q \in \mathbf{C}^{n \times n}$  为可逆矩阵使得

$$PAQ = \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix}$$

则

$$A^- = Q \begin{bmatrix} I_r & X \\ Y & Z \end{bmatrix} P$$

为矩阵  $A$  的广义逆，其中  $X, Y, Z$  为任意维数相容的矩阵。

# 矩阵的伪逆

- 定义：考虑  $A \in \mathbb{C}^{m \times n}$ ，若存在  $A^+ \in \mathbb{C}^{n \times m}$  满足以下等式

$$\begin{aligned}AA^+A &= A \\A^+AA^+ &= A^+ \\(AA^+)^H &= AA^+ \\(A^+A)^H &= A^+A\end{aligned}$$

则称  $A^+$  是矩阵  $A$  的伪逆，也称 Moore-Penrose pseudoinverse。

- 定理：考虑  $A \in \mathbb{C}^{m \times n}$ ，则其伪逆存在且唯一，其可以表示为

$$A^+ = C^H(CC^H)^{-1}(B^HB)^{-1}B^H$$

其中， $A = BC$  为  $A$  的一个满秩分解。

# 线性方程组的最小二乘解

- 定义：给定  $A \in \mathbf{C}^{m \times n}$ ，假设线性方程组  $Ax = b$  无解。若  $x^*$  满足

$$x^* = \min_{x \in \mathbf{C}^n} \|Ax - b\|_2$$

则称  $x^*$  是线性方程组的最小二乘解；长度最小的最小二乘解称为极小最小二乘解。

- 定理：定义：给定  $A \in \mathbf{C}^{m \times n}$ ，假设线性方程组  $Ax = b$  无解。则
  - 1. 其最小二乘解的通解为

$$x^* = A^+b + (I - A^+A)y$$

其中  $y \in \mathbf{C}^n$  为任意向量

- 2. 其唯一的极小最小二乘解为

$$\tilde{x}^* = A^+b$$

## 4.6 正规矩阵

- 回忆：若当标准型
- 问题：如果只允许用标准正交基，可将一个矩阵相似变换成什么？
- 定理：任一复方阵均酉相似于上三角矩阵。更具体地讲，给定  $A \in \mathbf{C}^{n \times n}$ ，一定有酉矩阵  $U \in \mathbf{C}^{n \times n}$  使得

$$U^{-1}AU$$

为上三角矩阵（以上即 Schur 定理）。



- 问题：给定任一复方阵，什么时候存在酉矩阵将其化为对角阵（几何视角如何解读）？
- 定义：若  $A \in \mathbb{C}^{n \times n}$  满足

$$A^H A = A A^H \quad (4)$$

即一个给定复方阵，若其共轭转置与其可交换，则称其为正规矩阵。

- 引理：若  $A$  同时是正规矩阵和上三角矩阵，则其是对角阵。
- 定理：给定  $A \in \mathbb{C}^{n \times n}$ ，存在酉矩阵  $U \in \mathbb{C}^{n \times n}$  使得  $U^{-1} A U$  为对角阵的充要条件是其为正规矩阵（几何视角如何解读）。

# 三种特殊正规矩阵的特征值

- 正规矩阵的例子
  - Hermite 矩阵
  - 反 Hermite 矩阵
  - 酉矩阵
- 给定正规矩阵  $A \in \mathbf{C}^{n \times n}$ , 则
  - $A$  是 Hermite 矩阵的充要条件是其特征值是实数
  - $A$  是反 Hermite 矩阵的充要条件是其特征值的实部为零
  - $A$  是酉矩阵的充要条件是其特征值的模长等于 1

# 正规矩阵的西相似对角化的具体过程

首先, 给定  $n$  阶正规矩阵  $A$ , 由前述定理知

- (a)  $A$  的特征值的代数重数等于其几何重数
- (b)  $A$  的对应于不同特征值的特征子空间相互正交

于是, 将  $A$  西相似对角化的具体过程是

- (1) 计算  $|\lambda I_n - A|$  的所有不同的根, 记为  $\lambda_1, \lambda_2, \dots, \lambda_p$
- (2) 对每个  $\lambda_i$ , 计算  $(\lambda_i I_n - A)x = 0$  的基础解系, 记为

$$v_1^i, v_2^i, \dots, v_{r_i}^i$$

- (3) 通过 Gram—Schmidt 标准正交化, 求得

$$u_1^i, u_2^i, \dots, u_{r_i}^i$$

- (4) 拼出  $\Lambda$

$$\Lambda = \text{diag}\{\lambda_i I_{r_i}\}$$

其中  $i = 1, 2, \dots, p$ ; 拼出  $U$  如下

$$U = \begin{bmatrix} u_1^1 & \cdots & u_{r_1}^1 & u_1^2 & \cdots & u_{r_2}^2 & \cdots & u_1^p & \cdots & u_{r_p}^p \end{bmatrix}$$

## 4.7 Hermite 矩阵与 Hermite 二次型

- 定理：给定  $A \in \mathbb{C}^{n \times n}$ ，则下列条件等价
  - (1)  $A$  为 Hermite 矩阵，即

$$A = A^H$$

- (2) 对任意的  $x, y \in \mathbb{C}^n$ ，都有

$$\langle Ax, y \rangle = \langle x, Ay \rangle$$

- 定义：给定  $n$  阶 Hermite 矩阵  $A$ 。映射

$$x \mapsto \langle Ax, x \rangle = x^H Ax$$

确定了从  $\mathbb{C}^n$  到  $\mathbb{R}$  的函数，称为 Hermite 二次型，写成分量形式有

$$x^H Ax = \sum_{i=1}^n \sum_{j=1}^n a_{ij} \bar{x}_i x_j$$

- 为什么 Hermite 二次型一定为实数？
  - (a)  $A$  为正规矩阵
  - (b)  $A$  的特征值均为实数

- 定义：给定  $n$  阶 Hermite 矩阵  $A$ 。若对任意的  $x \in \mathbf{C}^n$  且  $x \neq 0$ ，都有

$$x^H A x > 0 \ (\geq 0)$$

则称  $x^H A x$  为 Hermite 正定（半正定）二次型，称  $A$  为 Hermite 正定（半正定）矩阵。

- 定理：给定  $n$  阶 Hermite 矩阵  $A$ 。其为 Hermite 正定（半正定）矩阵的充要条件是其特征值均为正实数（非负实数）。
- 定理：给定  $n$  阶 Hermite 正定（半正定）矩阵  $A$ 。则存在唯一的 Hermite 正定（半正定）矩阵  $H$  使得

$$A = B^2$$

# Hermite 矩阵特征值的极值刻画

- 定理：给定  $n$  阶 Hermite 矩阵  $A$ ，其特征值  $\lambda_1, \lambda_2, \dots, \lambda_n$  均为实数，不妨假设

$$\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$$

则有

$$\lambda_{\min}(A) = \lambda_1 = \min_{x \in \mathbf{C}^n, x \neq 0} \frac{x^H A x}{x^H x} = \min_{x \in \mathbf{C}^n, \|x\|=1} x^H A x$$

$$\lambda_{\max}(A) = \lambda_n = \max_{x \in \mathbf{C}^n, x \neq 0} \frac{x^H A x}{x^H x} = \max_{x \in \mathbf{C}^n, \|x\|=1} x^H A x$$

- 注：Hermite 矩阵的 Rayleigh 商

$$R(x) := \frac{x^H A x}{x^H x}, \quad x \in \mathbf{C}^n, \quad x \neq 0$$

## 4.8 矩阵的奇异值分解

- 回忆：两个矩阵  $A, B \in \mathbf{F}^{m \times n}$  被称为是等价的，记为  $A \sim B$ ，如果存在  $n$  阶非奇异矩阵  $P \in \mathbf{F}^{n \times n}$  和  $m$  阶非奇异矩阵  $Q \in \mathbf{F}^{m \times m}$  使得

$$AP = QB$$

- 初等行列变换的标准型：对任意矩阵  $A \in \mathbf{F}^{m \times n}$ ，可以经过初等行列变换将  $A$  化为标准型，即存在  $n$  阶非奇异矩阵  $P \in \mathbf{F}^{n \times n}$  和  $m$  阶非奇异矩阵  $Q \in \mathbf{F}^{m \times m}$  使得

$$\begin{aligned} Q^{-1}AP &= \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} \\ \Leftrightarrow AP &= Q \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} \end{aligned}$$

- 问题：**若  $P$  和  $Q$  都是酉矩阵，那么  $A$  可以被变换成什么样子？

- 引理：给定矩阵  $X \in \mathbf{C}^{m \times n}$  且  $\text{rank}(X) = r$ ，则有
  - (a)  $X^H X$  和  $XX^H$  分别是  $m$  阶和  $n$  阶的 Hermite 半正定矩阵
  - (b)  $\text{rank}(X^H X) = \text{rank}(XX^H) = r$
- 定理：给定矩阵  $X \in \mathbf{C}^{m \times n}$  且  $\text{rank}(X) = r$ ，则存在酉矩阵  $U \in \mathbf{C}^{m \times m}$  和  $V \in \mathbf{C}^{n \times n}$  使得

$$U^H X V = \begin{bmatrix} \Sigma_r & 0_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{bmatrix}$$

其中，

$$\Sigma_r = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{bmatrix}$$

且  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r$ 。特别的，我们称

$$\sigma_i = \sqrt{\lambda_i(X^H X)}, i = 1, 2, \cdots, r$$

为矩阵  $X$  的奇异值。